

機器學習分步驟實驗 — Crop Recommendation

資料集特性（決定模型選擇的依據）

項目	數值	意義
筆數	2200	小資料集，複雜模型優勢不明顯
類別數	22 種作物	多分類問題
每類樣本數	各 100 筆	完全平衡，不需處理 class imbalance
特徵數	7 個	低維，不存在維度詛咒
缺失值	0	乾淨資料
重複列	極少	

特徵相關性（重要！）

- P 與 K 相關係數：**0.74**（顯著相關）##計算函式
- 其餘特徵相互獨立（相關係數 < 0.25）
- → NB 的「條件獨立假設」在 P-K 之間有點被違反，但其他特徵幾乎獨立

這份資料的核心性質：小、乾淨、平衡、低維

→ 傾向讓簡單模型表現好，複雜模型的優勢（正則化、速度優化）幾乎體現不出來

實驗主線

Step 0 → Step 1 → Step 2 → Step 3 → Step 4 → Step 5
DT+RF DT深入 RF+ET LR NB★ MLP

每步都有獨立學習意義：

- Step 3 LR：唯一會明顯低於 0.9955 的，確認問題是非線性
- Step 4 NB：用最簡單的假設撞到天花板，加特徵卻打壞它（核心故事）
- Step 5 MLP：小資料讓 NN 輸，學會模型適用邊界

每一步的邏輯：上一個模型的問題 → 這個模型的引入理由

Step 0 — 基線：Decision Tree + Random Forest

檔案： `train_crop_model_step0.py`

模型簡介

- **Decision Tree**：根據特徵值遞迴切割，找出最降低 Gini/Entropy 的切割點，建出一棵樹
- **Random Forest**：訓練多棵 DT（各用隨機子集的資料 + 隨機子集的特徵），投票決定結果

為什麼從這兩個開始？

樹狀模型對特徵尺度不敏感（不需要 StandardScaler），對這份 7 特徵的農業資料天然友好，是最直覺的起點。

結果

模型	Test Acc	CV Mean
Decision Tree	0.9750	0.9807
Random Forest	0.9909	0.9932

發現的問題

RF 明顯比 DT 強，但還不理解為什麼——只知道「多棵樹比較準」。
→ 需要深入理解 DT 的弱點才能真正明白 RF 在做什麼

Step 1 — DT 深入：發現過擬合

檔案： `train_crop_model_step1.py`

DT模型簡介

過擬合


決策樹（Decision Tree）是一種**非參數模型（Non-parametric Model）**，它的模型容量（Capacity）會隨著 `max_depth` 的增加而無限增長，為了在**偏誤（Bias）**與**變異（Variance）**之間取得最佳平衡，對複雜度進行敏感度分析（Sensitivity Analysis）。
資料太少，模型很容易把訓練集背起來

過擬合（Overfitting）的嚴格定義是：「**訓練集準確率持續上升，但測試集準確率開始下跌**」。

1.max_depth vs Train / Test Accuracy

監控模型的 **Generalization Gap (泛化差距)**。當差距大於 2% 時，代表模型開始出現『**變異性 (Variance) 擴大**』的傾向。雖然此時測試集的絕對準確率 (Test Acc) 還在上升，但兩者逐漸脫鉤，說明模型對訓練集的依賴度正在加速超越其泛化能力的增長。這是一個早期的過擬合預警訊號。」

max_depth vs Train / Test Accuracy		
depth=1	train=0.0909	test=0.0909
depth=2	train=0.1364	test=0.1364
depth=3	train=0.2273	test=0.2273
depth=4	train=0.3182	test=0.3182
depth=5	train=0.4091	test=0.4068
depth=6	train=0.5830	test=0.5705
depth=7	train=0.7608	test=0.7386 ← 過擬合開始
depth=8	train=0.8949	test=0.8705 ← 過擬合開始
depth=9	train=0.9443	test=0.9250
depth=10	train=0.9818	test=0.9636
depth=11	train=0.9898	test=0.9773
depth=12	train=0.9943	test=0.9795
depth=13	train=0.9966	test=0.9818
depth=14	train=0.9966	test=0.9818
depth=15	train=0.9983	test=0.9818
depth=16	train=0.9994	test=0.9795
depth=17	train=1.0000	test=0.9795 ← 過擬合開始
depth=18	train=1.0000	test=0.9795 ← 過擬合開始
depth=19	train=1.0000	test=0.9795 ← 過擬合開始
depth=20	train=1.0000	test=0.9795 ← 過擬合開始
depth=None(全深)	train=1.0000	test=0.9795 ← 過擬合開始



2. CV Variance (depth=None 最佳 depth 對比)

- **低 CV Variance**：代表無論抽到哪一份資料當驗證集，模型跑出來的分數都大同小異（例如都是 85% 左右）。這意味著模型非常**穩定**，沒有過度依賴特定的訓練樣本。
- **高 CV Variance**：代表模型在某些資料集分數極高（95%），在某些資料集卻崩潰（60%）。這意味著模型非常**不穩定**，對資料的隨機切分極度敏感，通常是過擬合（Overfitting）的強烈訊號。

Cross-Validation – 量化 DT 的 Variance

depth=3 (欠擬合)	CV=0.2261 ± 0.0023 (min=0.2216 max=0.2273)
depth=5 (平衡點附近)	CV=0.4074 ± 0.0023 (min=0.4034 max=0.4091)
depth=10 (過擬合)	CV=0.9750 ± 0.0068 (min=0.9688 max=0.9858)
depth=None (完全生長)	CV=0.9852 ± 0.0068 (min=0.9773 max=0.9943)

發現 depth = 10 和完全生長 幾乎一樣穩定，完全放開深度限制（depth=None），非但沒有讓模型崩潰（Variance 沒有擴大），反而讓準確率進一步提升。

如果 depth=10 已經過擬合，那更深的 depth=None 分數應該要往下掉，但它反而上升了。

資料集的訊噪比（Signal-to-Noise Ratio）極高：這說明我們的特徵品質非常好，內部包含的是確定性很高的深層邏輯（Deep Rules），而非隨機雜訊。因此，即使樹長得很深，它學到的依然是具備泛化能力的真實邊界，而不是硬記雜訊。

數據證實，在這個特定的 Task 上，傳統理論中『全深必定導致 Variance 崩潰』的假設並不成立。depth=None 才是本大題泛化能力（Generalization Ability）最強的最佳設定。

有沒有辦法在保留 DT 優點的情況下降低 variance ？

→ 引入 RandomForest，讓多棵樹投票

Step 2 — RF 深入：Bagging 降低 Variance

檔案：train_crop_model_step2.py

模型簡介

Bagging（Bootstrap Aggregating）的核心邏輯：

1. 從訓練集隨機抽取（有放回）多份子集
2. 在每份子集上訓練一棵 DT（且每次分裂只考慮隨機子集的特徵）
3. 多棵樹投票 → 單棵樹的隨機錯誤互相抵消

結果

****實驗 1：DT vs RF**

DT vs RF – Variance (CV Std) 直接對比

DT (depth=10)	Test=0.9636	CV=0.9750 ± 0.0068	
RF (100棵)	Test=0.9955	CV=0.9938 ± 0.0061	(std 降低 11%)

為什麼在這份資料上 RF 會贏 DT？

100 筆/類的小資料，單棵 DT 容易過擬合，多棵樹投票的穩定性直接體現

隨機森林用數據證明，它確實能強行把單一決策樹的 Variance 再往下壓低 11%，同時大幅拉高準確率。

這完美體現了 Ensemble Learning 的底層核心——在不犧牲（甚至提升）擬合能力的前提下，成功降低了模型的 Variance，徹底根治了決策樹的過擬合隱憂。」

實驗 2：n_estimators 邊際效益

n_estimators 邊際效益（多少棵樹才夠？）

n=1	Test=0.9591	CV=0.9494
n=5	Test=0.9955	CV=0.9852
n=10	Test=0.9932	CV=0.9909
n=20	Test=0.9955	CV=0.9898
n=50	Test=0.9955	CV=0.9932
n=100	Test=0.9955	CV=0.9938
n=200	Test=0.9955	CV=0.9943
n=300	Test=0.9932	CV=0.9938
n=500	Test=0.9955	CV=0.9938

分析

1. **n=5 就達到 0.9955 的 test acc**：但 CV mean 只有 0.9852，代表 n=5 對不同資料切法還不夠穩定，n=100 是穩定性和效率的甜蜜點
2. **Feature Importance 驗證農業邏輯**：rainfall 和 humidity 是最重要特徵，N/P/K 排後面——氣候比土壤養分更決定作物適性

引出的問題

RF 很強，但 Bagging 的邏輯是「降低 variance」，對 bias 幾乎沒幫助。有沒有不同的集成邏輯？

→ 引入 Boosting（序列修正錯誤，攻擊 bias）

Step 3 — Logistic Regression：先問線性夠不夠

檔案： `train_crop_model_step3.py`

模型簡介

假設 decision boundary 是線性的，用 sigmoid/softmax 輸出機率，最大化 log-likelihood。
訓練速度極快，可解釋性強，是任何 ML 實驗的**基準線**。

為什麼要試？

養成習慣：在用複雜模型之前，先確認問題是不是線性可分的。如果 LR 就能達到 99%，後面的複雜模型就不值得了。

為什麼在這份資料上預期會輸？

22 種作物的 decision boundary 很可能不是線性的——同一片特徵空間裡有 22 個區域，線性邊界無法乾淨切割。

預期要觀察的

- Acc 明顯低於 RF → 確認問題是非線性的
- 錯誤類別集中在「環境相似的作物」（如 rice vs jute）

結果

預設 LR (C=1) **

```
=====
Logistic Regression 基本結果
=====
```

```
Test Acc : 0.9727 (RF 天花板 0.9955, 差距 0.0228)
CV Mean  : 0.9682 ± 0.0066
```

- 結論：線性不夠，確認問題是非線性的

實驗 2：C 參數調整

正則化

在 LR 中，模型會幫每一個特徵（Rainfall, Humidity, P...）算出一組權重（Weights），然後把權重加總來做預測。

如果模型為了討好訓練集，把某些權重算得超級大（例如：只要 Rainfall > 30 權重直接給 + 一萬分），這個模型就會變得非常敏感、容易走火入魔。

「正則化（Regularization）」——只要權重敢變大，就給模型懲罰。

而你的程式碼裡的 C ，就是懲罰溫度的控制旋鈕。它的公式是 $C = \frac{1}{\lambda}$ （與懲罰強度成反比）：

- 當 C 非常小（如 0.001）：代表懲罰超級重（正則化極強）。模型嚇得要死，不敢給特徵任何權重，每個權重都接近 0。模型會變得超級簡單、笨拙、講不聽。
- 當 C 很大（如 1000）：代表幾乎沒有懲罰（正則化極弱）。模型完全放飛自我，為了迎合訓練集，權重愛設多大就設多大，模型會變得非常複雜。

如果調大 C 沒幫助，代表線性本身就是瓶頸

代表：「這份農業資料的作物邊界不是線性的，用直線去切根本切不乾淨（欠擬合），所以非用 RF 這種非線性模型不可。」

C 參數（正則化強度）的影響		
C=0.001	Test=0.7136	CV=0.6687
C=0.01	Test=0.8205	CV=0.7909
C=0.1	Test=0.9364	CV=0.9318
C=1	Test=0.9727	CV=0.9682
C=10	Test=0.9795	CV=0.9773
C=100	Test=0.9841	CV=0.9778
C=1000	Test=0.9841	CV=0.9767

→ 最高只到 0.9841， C 再大也不動了，線性模型到頂

Step 4 — Naive Bayes：意外的主角

檔案：train_crop_model_step4.py

模型簡介

貝葉斯定理：

$$P(class|features) \propto P(features|class) \times P(class)$$

Naive（天真）的假設：給定類別，所有特徵條件獨立

$$P(features|class) = \prod_i P(feature_i|class)$$

Gaussian NB：假設每個特徵在每個類別下服從高斯分佈，用訓練資料估計各類別的 μ 和 σ

這裡不會要考慮要不要解釋

NB 的思路完全不同：不找邊界，直接問「這筆資料的特徵值，在哪個作物的統計分佈下最合理？」

Gaussian NB 的兩個假設：

1. 特徵在給定類別下條件獨立 (Naive)
2. 每個特徵在每個類別下服從高斯分佈 (Gaussian)

實際結果

```
=====
Gaussian NB 基本結果 (原始 7 特徵)
=====

Test Acc : 0.9955
CV Mean  : 0.9949 ± 0.0042
vs RF    : 同一天花板
vs LR    : +0.0114 (比線性模型最佳成績好)
```

為什麼 NB 贏了？（找原因）

假設 1：Class separation 太強，假設的違反不重要


22 種作物各有獨特的「環境指紋」（rice 需要高降雨、coconut 需要高溫高濕等），各類別的 Gaussian 分佈在特徵空間中幾乎不重疊。即使 P-K 不獨立，只要 class 之間分得夠開，NB 還是能正確分類。

假設 2：小資料集 NB 的 variance 優勢

NB 只需要估計每個特徵在每個類別的 μ 和 σ ($7 \times 22 \times 2 = 308$ 個參數)，參數極少，不容易過擬合 100 筆/類的小資料。




Class-conditional 分佈 — NB 的假設1成不成立？

各作物在 rainfall 上的 mean $\pm$ std (看分離程度)：

muskmelon	24.7 $\pm$	2.8	
lentil	45.7 $\pm$	5.6	
mungbean	48.4 $\pm$	7.1	
watermelon	50.8 $\pm$	5.9	
mothbeans	51.2 $\pm$	13.8	
blackgram	67.9 $\pm$	4.2	
grapes	69.6 $\pm$	3.0	
chickpea	80.1 $\pm$	7.9	
cotton	80.4 $\pm$	11.2	
maize	84.8 $\pm$	15.5	
mango	94.7 $\pm$	3.3	
banana	104.6 $\pm$	9.4	
kidneybeans	105.9 $\pm$	26.1	
pomegranate	107.5 $\pm$	2.9	
orange	110.5 $\pm$	5.7	
apple	112.7 $\pm$	7.1	
papaya	142.6 $\pm$	64.4	
pigeonpeas	149.5 $\pm$	33.0	
coffee	158.1 $\pm$	25.7	
jute	174.8 $\pm$	15.1	
coconut	175.7 $\pm$	29.5	
rice	236.2 $\pm$	34.3	

特徵工程

Ratio 與 GaussianNB 的關係



特徵工程 – NB 的致命弱點

特徵組合	NB Acc	RF Acc	NB 變化
原始 7 特徵	0.9955	0.9955	+0.0000 ← 不變
全部 13 特徵	0.9932	0.9932	-0.0023 ← 下降！


[圖] 已儲存 models/step4_figs/ratio_feature_dist.png

加入 ratio 特徵後 NB 為什麼掉？

N/P_ratio、N/K_ratio 等比值特徵分佈是**右偏的**，根本不是 Gaussian。Gaussian NB 強行用正態分佈去擬合這些特徵，估計嚴重失準，反而傷害準確率。

RF 不在乎分佈，只在乎切割點，多一個特徵就多一個資訊。

Permutation Importance — NB 靠哪個特徵？



還沒解釋

總覽表（最終）

Step	模型	Test Acc	CV Mean	CV Std	備註	
0	Decision Tree (基...	0.9750	0.9807	0.0042		
0	Random Forest (基線)	0.9909	0.9932	0.0029		
1	DT (depth=10 調...	0.9636	0.9750	0.0068	過擬合可視化確認	
2	RF (100棵)	0.9955	0.9938	0.0061	天花板初次出現	
3	Logistic Regression	0.9841	0.9778	0.0066	線性上限， rice↔jute×4	

Step	模型	Test Acc	CV Mean	CV Std	備註	
4	NB (原始 7 特徵)	0.9955	0.9949	0.0042	★ 最穩，308 個參數	
4	NB (13 特徵)	0.9932	—	—	ratio 特徵破壞 Gaussian	
4	RF (13 特徵)	0.9932	—	—		

NB 的錯誤配對 (共 2 個錯誤)：

rice

→ jute

2 次

資料天花板：0.9955 (rice↔jute 2 筆邊緣樣本，各模型均無法突破)

核心學習總結

1. **天花板來自資料，不來自模型**：RF、NB 原理完全不同的模型都到了 0.9955，上不去是因為 rice/jute 的環境指紋本身有重疊，不是模型不夠強
2. **NB 用最少的假設到達天花板**：308 個參數，瞬間訓練，CV 最穩。原因是作物的 class-conditional Gaussian 分佈幾乎不重疊，P-K 相關的違反被 class separation 蓋過去了
3. **特徵工程是雙面刃**：ratio 特徵讓 NB 和 RF **同時下降**——和原始特徵線性相關的衍生特徵，對任何模型都是冗餘
4. **LR 確認了非線性**：線性邊界最高 0.9841，問題有非線性邊界
5. **複雜不等於更好**：在小、乾淨、平衡、低維的資料上，最簡單的模型往往就是最好的選擇